

Pertemuan II

Pada praktikum ini, Anda akan melakukan beberapa operasi dasar statistik dengan data bertema konstruksi yaitu data pembuatan semen (Cement Manufacturing).

- Histogram
- Box Plot
- Summary Statistics
- Relationship Between Variables
- Correlation
- Covariance
- Pearson Correlation
- Spearman's Rank Correlation
- Hypothesis Testing

Materi Praktikum Dikhususkan Untuk Program Studi:

Fakultas Teknologi Industri (FTI)

No	Program Studi	Jenjang
1	Informatika	Sarjana
2	Teknik Elektro	Sarjana

Fakultas Ilmu Komputer dan Teknologi Informasi (FIKTI)

No	Program Studi	Jenjang
1	Sistem Informasi	Sarjana
2	Sistem Komputer	Sarjana
3	Manajemen Informatika	Diploma Tiga
4	Teknik Komputer	Diploma Tiga

Overview Dataset

"Data Pembuatan Semen (Cement Manufacturing)"

Beton merupakan material terpenting dalam teknik sipil. Kuat tekan beton adalah fungsi yang sangat nonlinier dari umur dan bahan. Bahan-bahan tersebut antara lain semen, terak tanur tinggi, fly ash, air, superplasticizer, agregat kasar, dan agregat halus. Dataset ini berisi data mengenai kekuatan semen, bahan penyusun dan waktu campuran.

Kekuatan tekan beton (MPa) untuk campuran tertentu di bawah umur tertentu (hari) ditentukan dari informasi laboratorium. Data ini merupakan data (tidak diskalakan). Data memiliki 8 variabel input kuantitatif, dan 1 variabel output kuantitatif, dan 1030 kejadian (pengamatan).

Dataset ini berisikan beberapa kategori sebagai berikut:

- cement (kg)
- slag (blast furnace slag, kg)
- ash (fly ash, kg)
- water (kg)
- superplastic (superplasticizer, kg)
- coarseagg (coarse aggregate, kg)
- fineagg (fine aggregate, kg)
- age (days, 1-365)
- strength (Concrete compressive strength, MPa)

Instruksi Praktikum:

- Silakan modifikasi kode operasi yang ada menggunakan library perhitungan berbasis GPU (Library Cupy).
- Bacalah dataset yang tersimpan pada URL: <https://raw.githubusercontent.com/supasonix/ATA-praktikum-01/main/concrete.csv>.
- Periksa dataset apakah terdapat data yang bernilai null dengan menggunakan fungsi `.isnull()`.
- Buatlah sebuah histogram dari data kolom `"strength"`.
- Buatlah diagram boxplot dari dataset yang ada.
- Hitung karakteristik statistik (standar deviasi, variance, mean, median) dari masing-masing kolom data.
- Buatlah correlation map dari dataset tersebut.
- Hitung covariance dari kolom data yang diminta.
- Hitung pearson correlation dan spearsman correlation dari kolom data yang diminta.
- Hitung nilai hipotesis testing untuk kolom `"age"` dan `"strength"`.

JAWABAN

Catatan!
Pada bagian `#CODE HERE <...>` isi dengan code python sesuai dengan perintah.

Import Libraries

```
In [1]: # Import library yang digunakan dalam notebook ini

import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from pandas.plotting import autocorrelation_plot
from scipy import stats
plt.style.use("ggplot")

import warnings
warnings.filterwarnings("ignore")
```

Membaca Dataset

```
In [2]: # Membaca data sebagai pandas data frame
url_data = "https://raw.githubusercontent.com/supasonix/ATA-praktikum-01/main/concrete.csv"
data = pd.read_csv(url_data)

In [3]: # Melihat 5 baris awal dari dataset yang digunakan
data.head()

Out[3]:
   cement  slag  ash  water  superplastic  coarseagg  fineagg  age  strength
0    141.3  212.0   0.0  203.5           0.0      971.8   748.5   28    29.89
1    168.9   42.2  124.3  158.3          10.8     1080.8   796.2   14    23.51
2    250.0   0.0   95.7  187.4           5.5      956.9   861.2   28    29.22
3    266.0  114.0   0.0  228.0           0.0      932.0   670.0   28    45.85
4    154.8  183.4   0.0  193.3          9.1     1047.4   696.7   28    18.29

In [4]: # Melihat dimensi dataset
data.shape

Out[4]:
(1030, 9)

In [5]: # Melihat kolom dataset
data.columns

Out[5]:
Index(['cement', 'slag', 'ash', 'water', 'superplastic', 'coarseagg',
       'fineagg', 'age', 'strength'],
      dtype='str')

In [6]: # Cetak nilai rata rata kekuatan semen pada dataset
print("Nilai mean dari kolom strength:",data['strength'].mean())

Nilai mean dari kolom strength: 35.817961165048544
```

```
In [7]: # Periksa dataset apakah terdapat data yang bernilai null dengan menggunakan fungsi .isnull()
data.isnull()
```

```
Out[7]:
```


	cement	slag	ash	water	superplastic	coarseagg	fineagg	age	strength
0	False	False	False	False	False	False	False	False	False
1	False	False	False	False	False	False	False	False	False
2	False	False	False	False	False	False	False	False	False
3	False	False	False	False	False	False	False	False	False
4	False	False	False	False	False	False	False	False	False
...	...	...	...	...	...	...	...	...	...
1025	False	False	False	False	False	False	False	False	False
1026	False	False	False	False	False	False	False	False	False
1027	False	False	False	False	False	False	False	False	False
1028	False	False	False	False	False	False	False	False	False
1029	False	False	False	False	False	False	False	False	False

1030 rows x 9 columns

Histogram

- Menampilkan berapa kali (frekuensi) setiap nilai muncul dalam suatu kumpulan data.
- Frequency (frekuensi) adalah jumlah berapa kali setiap nilai muncul dalam suatu kumpulan data.
- Contoh: [1, 1, 1, 1, 2, 2, 2]. Frekuensi nilai 1 adalah empat, sedangkan frekuensi nilai 2 adalah tiga.
- Jenis deskripsi ini disebut distribusi variabel.
- Cara yang paling umum untuk merepresentasikan distribusi variabel adalah menggunakan histogram, yaitu grafik yang menunjukkan frekuensi kemunculan setiap nilai.


```
In [8]: # Buatlah histogram dari kolom 'strength'
plt.figure(figsize = (10,6))
plt.hist(data.strength, bins = 30, fc = (0,0,1,0.5), label = 'Kuat Tekan Beton (MPa)')
plt.xlabel('Strength (MPa)')
plt.ylabel('Frequency')
plt.title('Histogram Distribusi Kekuatan Tekan Beton')
plt.legend()
plt.show()
```



Box Plot

- Box plot adalah grafik yang digunakan untuk menggambarkan distribusi data berdasarkan nilai minimum, kuartil pertama (Q1), median (Q2), kuartil ketiga (Q3), dan nilai maksimum.
- Box plot dapat membantu kita melihat sebaran data, nilai tengah (median), serta outlier dalam suatu kumpulan data.
- Coba temukan nilai yang termasuk outlier pada dataset ini.

```
In [9]: # Buatlah boxplot dari kolom 'strength'
plt.figure(figsize = (10,6))
sns.boxplot(x = data.strength, color = (1,0,0,0.4))
plt.xlabel('Strength (MPa)')
plt.title('Boxplot Distribusi Kekuatan Tekan Beton')
plt.show()
```



```
In [10]: # Berikan penjelasan dari hasil visualisasi boxplot di atas
# -
# * Garis di tengah kotak (median) menunjukkan nilai tengah kekuatan beton,
#   yaitu sekitar 40 MPa.
# * Panjang kotak menunjukkan rentang interkuartil (Q1 sampai Q3), yaitu 50% data
#   berada di dalam kotak tersebut.
# * Jarak dari whisker ke kotak menunjukkan sebaran data di luar kuartil, dan
#   titik-titik di luar whisker merupakan outlier. Outlier terdapat pada nilai
#   kekuatan di bawah 10 MPa, yang berarti ada campuran beton yang sangat lemah.
# * Boxplot ini tidak simetris, ipan atau whiskernya Lebih panjang ke arah nilai
#   rendah. Artinya distribusi data_strength lebih banyak mengelompok di nilai
#   yang rendah dan memiliki ekor panjang ke arah kanan (positif/right-skewed).
```

Summary Statistics

Summary statistics atau statistik ringkasan digunakan untuk memberikan gambaran umum mengenai karakteristik suatu kumpulan data.

- Mean (rata-rata): menunjukkan nilai rata-rata dari seluruh data.
- Variance (varians): menunjukkan tingkat penyebaran data terhadap nilai rata-ratanya.
- Standard deviation (simpangan baku): merupakan akar kuadrat dari varians dan menunjukkan seberapa jauh data cenderung menyebar dari nilai rata-rata.



```
In [11]: # Hitung karakteristik data dari masing-masing kolom dengan menggunakan perintah describe.
# Menampilkan count, mean, std (standar deviasi), min, kuartil, dan max
data.describe()
```

Out[11]:

	cement	slag	ash	water	superplastic	coarseagg	fineagg	age	strength
count	1030.000000	1030.000000	1030.000000	1030.000000	1030.000000	1030.000000	1030.000000	1030.000000	1030.000000
mean	281.167864	73.895825	54.188350	181.567282	6.204660	972.918932	773.580485	45.662136	35.817961
std	104.506364	86.279342	63.997004	21.354219	5.973841	77.753954	80.175980	63.169912	16.705742
min	102.000000	0.000000	0.000000	121.800000	0.000000	801.000000	594.000000	1.000000	2.330000
25%	192.375000	0.000000	0.000000	164.900000	0.000000	932.000000	730.950000	7.000000	23.710000
50%	272.900000	22.000000	0.000000	185.000000	6.400000	968.000000	779.500000	28.000000	34.445000
75%	350.000000	142.950000	118.300000	192.000000	10.200000	1029.400000	824.000000	56.000000	46.135000
max	540.000000	359.400000	200.100000	247.000000	32.200000	1145.000000	992.600000	365.000000	82.600000

Relationship Between Variables


- Kita dapat mengatakan bahwa dua variabel memiliki hubungan apabila perubahan pada salah satu variabel berkaitan dengan perubahan pada variabel lainnya.
- Contoh: Harga dan jarak perjalanan taksi. Semakin jauh jarak perjalanan, biasanya semakin tinggi harga yang harus dibayar. Oleh karena itu, harga dan jarak memiliki hubungan positif.
- Salah satu cara termudah untuk melihat hubungan antara dua variabel adalah menggunakan scatter plot.




Correlation

- Correlation (korelasi) adalah ukuran yang menunjukkan arah dan kekuatan hubungan antara dua variabel.
- Nilai korelasi berada antara -1 hingga 1:
 - Mendekati 1 → hubungan positif yang kuat.
 - Mendekati -1 → hubungan negatif yang kuat.
 - Mendekati 0 → tidak terdapat hubungan linear yang kuat.

Perlu diingat bahwa korelasi tidak selalu berarti hubungan sebab-akibat (causation).





Covariance

- Covariance (kovarians) adalah ukuran yang menunjukkan kecenderungan dua variabel untuk berubah secara bersama-sama.
- Kovarians membantu kita mengetahui arah hubungan antara dua variabel:
 - Kovarians positif → ketika satu variabel meningkat, variabel lainnya cenderung ikut meningkat.
 - Kovarians negatif → ketika satu variabel meningkat, variabel lainnya cenderung menurun.
 - Kovarians mendekati nol → tidak terdapat hubungan linear yang jelas antara kedua variabel.

Dalam konteks vektor, kovarians dapat bernilai positif ketika kedua variabel cenderung bergerak ke arah yang sama dan negatif ketika bergerak ke arah yang berlawanan. Namun, istilah ortogonal lebih tepat digunakan untuk menjelaskan dot product atau hubungan geometris antarvektor, bukan sebagai definisi utama kovarians.

```
In [15]: # Bandingkan nilai covariance diantara kolom 'strength' dengan kolom 'age' dan kolom 'cement'
np.cov(data.strength, data.age)
print("Covariance strength dan age: ", data.strength.cov(data.age))
print("Covariance strength dan cement: ", data.strength.cov(data.cement))
```

Covariance strength dan age: 347.0597575174315
Covariance strength dan cement: 869.1439218900418

Pearson Correlation

- Pearson correlation (korelasi Pearson) adalah ukuran yang digunakan untuk mengetahui arah dan kekuatan hubungan linear antara dua variabel.
- Korelasi Pearson dapat dihitung dengan membagi covariance antara dua variabel dengan hasil kali standar deviasi masing-masing variabel.

$$\text{Pearson correlation} = \frac{\text{Cov}(A, B)}{\text{Std}(A) \times \text{Std}(B)}$$

- Nilai korelasi Pearson berada antara -1 hingga 1:
 - Mendekati 1 → hubungan positif yang sangat kuat.
 - Mendekati -1 → hubungan negatif yang sangat kuat.
 - Mendekati 0 → hubungan linear yang lemah atau tidak ada.

```
In [16]: # Hitung nilai pearson correlation dari kolom 'cement' dan 'age'
p1 = data.loc[:,['cement','age']].corr(method = 'pearson')
p2 = data.cement.cov(data.age) / (data.cement.std() * data.age.std())
print('Pearson correlation dengan metode .corr():')
print(p1)
print('Pearson correlation dengan definisi manual: ', p2)

Pearson correlation dengan metode .corr():
      cement      age
cement  1.000000  0.081946
age      0.081946  1.000000
Pearson correlation dengan definisi manual:  0.08194602387182237
```

Spearman's Rank Correlation

- Spearman's Rank Correlation (korelasi peringkat Spearman) adalah metode untuk mengukur arah dan kekuatan hubungan antara dua variabel berdasarkan peringkat (rank) datanya.
- Korelasi Pearson bekerja dengan baik ketika hubungan antara dua variabel bersifat linear. Namun, Pearson cukup sensitif terhadap outlier, sehingga adanya nilai pencilan dapat memengaruhi hasil korelasi.
- Korelasi Spearman menggunakan peringkat setiap nilai, sehingga lebih tahan terhadap pengaruh outlier dibandingkan korelasi Pearson.

```
In [17]: # Hitung nilai spearman rank dari kolom data 'age' dan 'strength'
s1 = data.loc[:,['age','strength']].corr(method = 'spearman')
ranked_data = data.rank()
s2 = ranked_data.loc[:,['age','strength']].corr(method = 'pearson')
print("Spearman's rank correlation:")
print(s1)
print("Spearman's correlation dengan teknik peringkat (rank):")
print(s2)

Spearman's rank correlation:
      age strength
age      1.000000  0.596028
strength 0.596028  1.000000
Spearman's correlation dengan teknik peringkat (rank):
      age strength
age      1.000000  0.596028
strength 0.596028  1.000000
```

Hypothesis Testing

- Pengujian hipotesis digunakan untuk menentukan apakah suatu efek atau hubungan yang terlihat pada sampel cukup kuat untuk dianggap sebagai bukti adanya hubungan pada populasi.
- Langkah pertama adalah mengukur ukuran efek nyata dengan memilih statistik uji. Pilihan alami untuk statistik uji adalah perbedaan mean atau rata-rata antara dua kelompok.
- Langkah kedua adalah mendefinisikan hipotesis nol yaitu model sistem berdasarkan asumsi bahwa efek yang tampak tidak nyata. Hipotesis nol adalah jenis hipotesis yang digunakan dalam statistik yang menyatakan bahwa tidak ada signifikansi statistik dalam serangkaian pengamatan yang diberikan. Hipotesis nol adalah hipotesis yang orang mencoba untuk menyangkalnya. Hipotesis alternatif adalah hipotesis yang orang ingin mencoba untuk membuktikannya.
- Langkah ketiga adalah menghitung p-value yaitu probabilitas melihat efek nyata jika hipotesis nol benar. Misalkan kita memiliki uji hipotesis nol. Kemudian kita hitung nilai p. Jika nilai p kurang dari atau sama dengan ambang batas, kami menolak hipotesis nol.
- Jika p-value rendah, pengaruh tersebut dikatakan signifikan secara statistik artinya tidak mungkin terjadi secara kebetulan. Oleh karena itu kita dapat mengatakan bahwa efeknya lebih mungkin muncul pada populasi yang lebih besar.
- Contoh: Diketahui bahwa:
 - Hipotesis nol: dunia rata.
 - Hipotesis alternatif: dunia itu bulat.Beberapa ilmuwan mulai menyangkal hipotesis nol. Ini akhirnya mengarah pada refleksi hipotesis nol dan penerimaan hipotesis alternatif.
- Jika nilai p rendah, kami menyimpulkan bahwa hipotesis nol tidak mungkin benar.
- Contoh berdasarkan data pada pertemuan sebelumnya:
 - Saya ingin mengetahui apakah rata-rata radius dan rata-rata area terkait satu sama lain? Hipotesis nol saya adalah bahwa "hubungan antara rata-rata radius dan rata-rata area adalah nol pada populasi tumor".
 - Sekarang kita perlu menyangkal hipotesis nol ini menggunakan p-value untuk menunjukkan bahwa rata-rata radius dan rata-rata area berhubungan (walaupun sebenarnya kita telah mengetahui hasilnya berdasarkan analisa korelasi yang telah dilakukan sebelumnya).

```
In [18]: # Lakukan hubungan hipotesis data antara kolom 'age' dan 'strength'
```

```
# Hipotesis nol (H0): tidak ada hubungan antara umur beton dan kekuatan tekannya
# Hipotesis alternatif (H1): ada hubungan antara umur beton dan kekuatan tekannya
statistic, p_value = stats.ttest_rel(data.age, data.strength)
print('Statistik uji:', statistic)
print('p-value adalah: ', p_value)
print('Tingkat signifikansi: ', 0.05)
if p_value < 0.05:
    print('Kesimpulan: menolak hipotesis nol, terdapat hubungan signifikan antara umur dan kekuatan beton')
else:
    print('Kesimpulan: tidak menolak hipotesis nol, tidak terdapat hubungan signifikan')
```

Statistik uji: 5.283669054951027
p-value adalah: 1.545311719208924e-07
Tingkat signifikansi: 0.05
Kesimpulan: menolak hipotesis nol, terdapat hubungan signifikan antara umur dan kekuatan beton

Perhatian! Konversi file IPYNB menjadi PDF untuk melakukan pengumpulan tugas di V-Class. [\[VIDEO\]](#)